

การศึกษาแบบจำลองในการตรวจจับต้นมันสำปะหลัง  
จากภาพถ่ายทางอากาศยานไร้คนขับโดยใช้การเรียนรู้เชิงลึก  
Model for Detection of Cassava Tree  
from Unmanned Aerial Vehicle Imagery Using Deep Learning

มณีนีรัตน์ ผลประเสริฐ<sup>1\*</sup> บัณฑิต สุวรรณโท<sup>2</sup> พงษ์ศธร เชิดสม<sup>3</sup>  
E-mail: phonprasert@gmail.com

บทคัดย่อ

ในปัจจุบันประเทศไทยกำลังประสบปัญหาจากการระบาดของโรคทางใบมันสำปะหลัง ซึ่งก่อให้เกิดผลเสียต่อปริมาณผลผลิตและการส่งออกในภาคอุตสาหกรรม โดยโรคระบาดทางใบที่สำคัญของมันสำปะหลัง ได้แก่ โรคใบไหม้ โรคใบจุดสีน้ำตาล โรคใบจุดไหม้ โรคใบจุดขาว โรคพุ่มแจ้และโรคใบด่างมันสำปะหลัง เป็นต้น จากการสำรวจข้อมูลภาคสนามในเบื้องต้น ผู้วิจัยได้ตระหนักถึงความสำคัญในการแก้ปัญหาดังกล่าว โดยใช้เครื่องมือในการเก็บข้อมูลภาพจากอุปกรณ์อากาศยานไร้คนขับ (UAV) ร่วมกับการวิเคราะห์ประมวลผลภาพด้วยแบบจำลองทางการเรียนรู้เชิงลึก (Deep Learning) โดยงานวิจัยนี้มีวัตถุประสงค์เพื่อศึกษาแบบจำลองในการตรวจจับต้นมันสำปะหลังจากภาพถ่ายทางอากาศยานไร้คนขับโดยใช้การเรียนรู้เชิงลึก ที่สามารถนำมาใช้ตรวจจับเพื่อระบุตำแหน่งของต้นมันสำปะหลังในแปลงให้ได้ก่อนทำการวิเคราะห์หาโรคในตำแหน่งของต้นมันสำปะหลัง ผู้วิจัยจึงได้ศึกษาใช้แบบจำลอง YOLO v3 ที่เป็นโมเดล Convolutional Neural Network (CNN) มาใช้ในงานตรวจจับวัตถุ (Object Detection) ในภาพถ่ายอากาศยานไร้คนขับจากการศึกษาได้แสดงให้เห็นว่าโมเดล YOLO v3 ได้ค่าผลจากการเรียนรู้ของแบบจำลอง training จำนวน 100 รอบ (epoch) ผลที่ได้คือ ค่า mAP 80.3% ค่า precision 76.2% และค่า recall 72.7% สรุปได้ว่าแบบจำลองโมเดล YOLO v3 สามารถนำมาใช้ตรวจจับต้นมันสำปะหลังจากภาพถ่ายทางอากาศยานไร้คนขับได้

**คำสำคัญ:** อากาศยานไร้คนขับ ต้นมันสำปะหลัง การเรียนรู้เชิงลึก การตรวจจับ

Abstract

At present, Thailand is experiencing the problem of an epidemic of cassava leaf diseases. Which negatively affects the output and exports in the industrial sector. The major epidemics of cassava are: cassava bacterial blight, brown leaf spot, white spot, witches broom, and cassava mosaic diseases. From preliminary field surveys, the researchers realized the importance of solving such problems by using a tool to collect image data from Unmanned Aerial Vehicle (UAV) equipment combined with image processing analysis with deep learning models. The purpose of this research is to study a model for detecting cassava trees from unmanned aerial vehicle images using deep learning that can be used to detect and identify the location of the cassava tree in the plot before analyzing the disease. The researcher has therefore studied the use of the YOLO v3 model, a Convolutional Neural Network (CNN) model, used in object detection in unmanned aerial vehicle images. The study result has shown that the YOLO v3 model with 100 epoch of training model is the mAP equal to 80.3%, precision is equal to 76.2%, and recall is equal to 72.7%. It can be used to detect cassava trees in plants plot from unmanned aerial vehicles images too.

**Keywords:** UAV, cassava tree, deep learning, detection

<sup>1,2</sup> อาจารย์ประจำหลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาเทคโนโลยีสารสนเทศ คณะเทคโนโลยีสารสนเทศ มหาวิทยาลัยราชภัฏมหาสารคาม

<sup>3</sup> นักวิชาการ/นักวิจัยทั่วไป อำเภอเมืองขอนแก่น จังหวัดขอนแก่น

## ความเป็นมาของปัญหา

พืชเศรษฐกิจทางการเกษตรที่สำคัญของประเทศไทยในปัจจุบัน ได้แก่ ข้าว ยางพารา อ้อย มันสำปะหลัง และปาล์ม ซึ่ง “มันสำปะหลัง” จัดให้เป็นพืชเศรษฐกิจลำดับที่ 4 ที่นิยมปลูกมากในพื้นที่ภูมิภาคตะวันออกเฉียงเหนือ (สำนักงานเศรษฐกิจการเกษตร, 2563) ซึ่งในการเพาะปลูกมันสำปะหลัง พบว่า เกษตรกรจะประสบปัญหาหลักที่สำคัญคือ การเกิดโรคระบาดที่เรียกว่า “โรคใบด่างมันสำปะหลัง” ซึ่งเป็นโรคพืชของมันสำปะหลังที่ต้องให้ความสำคัญเป็นอย่างมากเนื่องจากก่อให้เกิดผลกระทบรุนแรงต่อผลผลิตหัวมันสำปะหลังสดที่ลดลงมากถึง 80% - 100% (สำนักวิจัยพัฒนาการอารักขาพืช กรมวิชาการเกษตร, 2561) มีการแสดงอาการบนใบ คือ โรคทางใบ โดยจะแสดงลักษณะเด่นของความผิดปกติที่ส่วนใบ ที่นักพยาธิวิทยาพืชสามารถระบุได้ผ่านการตรวจสอบด้วยสายตา และในปัจจุบันก็ได้มีเทคโนโลยีการเกษตรแม่นยำที่เริ่มเข้ามามีบทบาทช่วยในด้านการเกษตรให้มีประสิทธิภาพมากยิ่งขึ้น โดยช่วยให้เกษตรกรสามารถจัดการและควบคุมการเพาะปลูก เพื่อให้มีผลผลิตที่มีคุณภาพและส่งถึงผู้บริโภคได้อย่างเพียงพอต่อความต้องการ นั่นคือ การใช้เทคโนโลยีอากาศยานไร้คนขับ (Unmanned Aerial Vehicle Technology: UAV) โดยมีงานวิจัยที่นำภาพถ่ายจากอากาศยานไร้คนขับมาใช้แก้ปัญหาด้านการวิเคราะห์โรคใบด่างในพืชที่หลากหลายวิธี ดังจะเห็นได้จากบทความวิจัยการวิเคราะห์ภาพถ่ายอากาศยานไร้คนขับในช่วงคลื่นแสง RGB ร่วมกับการใช้โมเดลสี (Color Space) และดัชนีพืชพรรณ (Vegetation Index: VI) ในการตรวจจับโรคที่เกิดในต้นอุน (M. Kerkech, A. Hafiane, 2018) ด้วยโมเดลการเรียนรู้เชิงลึก (Deep Convolutional Neural Network: DCNN) ทำให้ค่าความแม่นยำของการตรวจหาโรครวมกว่า 98.8% และในเวลาต่อมาได้มีการนำเสนอและพัฒนาวิธีการตรวจหาโรครานี้ในค่าในผลอุนและในใบอุนด้วยภาพถ่ายจากอากาศยานไร้คนขับด้วยกล้องถ่ายภาพมัลติสเปกตรัมร่วมกับเทคนิคการจัดเรียงภาพ (image registration) ใช้โมเดลการเรียนรู้เชิงลึก (M. Kerkech, A. Hafiane and R. Canals, 2020) ในการประมวลผลทำให้ได้ค่าความแม่นยำอยู่ที่ 92% และ 87% ตามลำดับ ซึ่งเป็นการต่อยอดจากงานวิจัยก่อนหน้านี้ที่พัฒนาจากภาพ RGB เป็นภาพ Multispectral แต่ถึงแม้งานวิจัยทั้งสองชิ้นที่กล่าวมาข้างต้นนี้จะได้ค่าความแม่นยำสูง แต่ในขั้นตอนการตรวจจับจะใช้เทคนิคการแบ่งส่วนภาพสำหรับการหาโรครานี้ในต้นพืชที่เป็นเถาเลื้อย อีกทั้งยังเป็นวิธีการเพื่อค้นหาวัดจุดในระดับ pixel จึงเป็นวิธีการที่ช้าและไม่เหมาะสมในการนำมาใช้หาตำแหน่งของต้นมันที่มุ่งพัฒนาให้โมเดลสามารถตรวจจับและคัดแยกต้นมันสำปะหลังตามลักษณะทรงพุ่มของต้นมันสำปะหลัง

จากรายงานวิจัยที่กล่าวมาแล้วข้างต้น ผู้วิจัยเล็งเห็นว่าปัจจุบันการทำการเกษตรในประเทศไทย มีการพัฒนาและนำเอาเทคโนโลยีอากาศยานไร้คนขับเข้ามาช่วยงานในการดำเนินกิจกรรมทางการเกษตรมากขึ้น ตั้งแต่กระบวนการรดน้ำ การให้ฮอร์โมน การให้ปุ๋ย การฉีดพ่นยากำจัดวัชพืชและแมลงศัตรูพืช การเก็บเกี่ยวและประมาณการผลผลิต รวมถึงใช้ในการสำรวจ วางแผน และถ่ายภาพวิเคราะห์ ตรวจสอบและเฝ้าติดตาม การวินิจฉัยโรคและระบุโรคในแปลงเพาะปลูก เพื่อสังเกตการเจริญเติบโตและการผิดปกติของพืชหากมีการระบาดของโรคพืชได้ ดังนั้น เพื่อให้การเฝ้าระวังโรคในมันสำปะหลังของเกษตรกรมีประสิทธิภาพสูงสุด ผู้วิจัยจึงให้ความสำคัญในส่วนของการตรวจจับต้นมันสำปะหลังจากภาพถ่ายอากาศยานไร้คนขับเป็นขั้นตอนสำคัญในลำดับแรกที่จะช่วยให้เกษตรกรสามารถทราบตำแหน่งของต้นมันสำปะหลังในแปลงที่มีความผิดปกติหรือเป็นโรคได้ โดยมีข้อดีในการเข้าถึงการสำรวจพื้นที่แปลงมันที่มีข้อจำกัดในเรื่องจำนวนแรงงานและเวลาในการเข้าถึง ตลอดจนเหมาะสมต่อการตรวจหาโรคในใบมันสำปะหลังได้ทั่วถึงในบริเวณกว้างได้ รวมทั้งทำให้ประหยัดเวลาและค่าใช้จ่ายในการจ้างแรงงานเข้าสำรวจโรคระบาดในแปลง และการใช้ภาพถ่ายทางอากาศยานไร้คนขับยังสามารถกำหนดข้อมูลขอบเขตและวางแผนการบินถ่ายภาพได้สะดวก เลือกเวลาถ่ายภาพได้ ทำให้มีความยืดหยุ่นในการสำรวจมากกว่าวิธีอื่น ข้อมูลภาพถ่ายอากาศยานไร้คนขับมีความเป็นปัจจุบันมากกว่า และใช้อุปกรณ์สำรวจที่มีความทันสมัย ใช้เทคโนโลยีการสำรวจที่เป็นมาตรฐานที่ได้รับการยอมรับทั้งภาครัฐและเอกชนในด้านเกษตรกรรมมากขึ้นอย่างต่อเนื่อง อีกทั้งการนำมาประยุกต์ใช้งานร่วมกับอัลกอริทึมวิธีการเรียนรู้เชิงลึก (Deep Learning) ที่เป็นโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) มีความสามารถโดดเด่นในการสกัดคุณลักษณะเด่นของภาพ (Feature Extraction) ได้จากรูปแบบ (Pattern) รูปทรง (Shape) และค่าสีของแต่ละจุดภาพ (Color Space) จึงเป็นเหตุผลที่ผู้วิจัยได้เลือกแนวทางที่จะใช้อัลกอริทึมการเรียนรู้เชิงลึกที่มีโครงสร้างแบบ CNN มาประมวลผลข้อมูลประเภทรูปภาพที่มีความซับซ้อนมาใช้แก้ปัญหา เหมาะกับข้อมูลที่ไม่มีโครงสร้างได้ ซึ่งปัจจุบันโครงสร้างประสาทเทียมแบบ CNN ได้รับความนิยมและได้รับการยอมรับในการนำมาใช้งานที่หลากหลายมากขึ้นในด้านการทำเกษตรกรรมแม่นยำ (Precision Agriculture: PA) เช่น การค้นหาตำแหน่ง (Localization) การตรวจจับ (Detection) การวินิจฉัย (Diagnosis) การจำแนก (Classification) และการจัดกลุ่ม (Clustering) รวมทั้งการแบ่งส่วน (Segmentation) จากข้อมูลภาพได้อีกทางหนึ่งที่จะทำให้เกิดประโยชน์สูงสุดต่อการพัฒนาด้านเกษตรกรรมของไทยในอนาคตได้

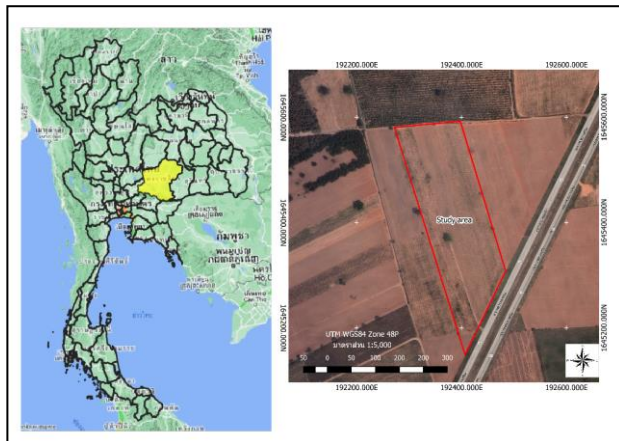
## วัตถุประสงค์ของการวิจัย

เพื่อศึกษาความเป็นไปได้ในการตรวจจับต้นมันสำปะหลังโดยใช้การเรียนรู้เชิงลึกและการวิเคราะห์ภาพถ่ายทางอากาศยานไร้คนขับ

## วิธีดำเนินการวิจัย

### 1. พื้นที่ของการศึกษา

การวิจัยนี้เป็นการวิจัยเชิงทดลอง โดยได้เลือกตัวแทนพื้นที่การศึกษาเป็นแปลงมันสำปะหลังพันธุ์เกษตรศาสตร์ 50 (KU50) ที่มีอายุปลูกที่ 3 เดือน โดยตั้งอยู่บนพิกัด  $14^{\circ}51'49.3''\text{N}$   $102^{\circ}08'31.0''\text{E}$  ตำบลไชยมงคล อำเภอเมือง จังหวัดนครราชสีมา มีขนาดพื้นที่ 16 ไร่ ดังภาพที่ 1



ภาพที่ 1 ตำแหน่งและลักษณะทางภูมิศาสตร์ของพื้นที่แปลงมันสำปะหลังที่ใช้ในการศึกษา ตำบลไชยมงคล อำเภอเมือง จังหวัดนครราชสีมา

### 2. เครื่องมือที่ใช้ในการเก็บข้อมูล

#### 2.1 ฮาร์ดแวร์

2.1.1 โดรน (Drone) หรืออากาศยานไร้คนขับ (UAV: Unmanned Aerial Vehicle) ใช้สำหรับการบินสำรวจเก็บข้อมูลภาคสนามของไร่มันสำปะหลังอายุ 1 เดือน และ 3 เดือน

2.1.2 กล้องมัลติสเปกตรัม ใช้สำหรับถ่ายภาพหลายช่วงคลื่นเพื่อสำรวจไร่มันสำปะหลัง

#### 2.2 ซอฟต์แวร์

2.2.1 โปรแกรม Qgis

2.2.2 โปรแกรม Pix4D โปรแกรมรวมภาพถ่ายอากาศยานไร้คนขับ โดยจะได้ภาพแต่ละช่วงคลื่นทั้งหมด 5 band ได้แก่ R, G, B, NIR, RedEdge

2.2.3 โปรแกรม Google Colab

2.2.4 Python 3

2.2.5 Keras

2.2.6 Tensorflow



ภาพที่ 2 เครื่องมือที่ใช้ในการเก็บข้อมูล


### 3. การเก็บรวบรวมข้อมูล

สามารถแบ่งออกเป็นขั้นตอน 2 ส่วน ได้แก่ ส่วนที่ 1 การสำรวจข้อมูลภาคสนาม ส่วนที่ 2 การเตรียมชุดข้อมูลสำหรับพัฒนาฝึกฝนโมเดล

3.1 การสำรวจข้อมูลภาคสนาม ในการสำรวจภาคสนามเพื่อทำแผนที่ภาพถ่ายด้วยอากาศยานไร้คนขับจำเป็นต้องกำหนดจุดควบคุมภาพ (GCP) สำหรับการกำหนดพิกัด Georeferencing และช่วยในการตรวจสอบความถูกต้องของแผนที่ โดยต้องวางจุด GCP ให้ครอบคลุมพื้นที่การศึกษาตามความลาดชัน ซึ่งในการศึกษานี้ได้ทำการวางจุด GCP จำนวน 7 จุด ดังแสดงในภาพที่ 3 และภาพที่ 4



ภาพที่ 3 แสดงการวางจุด Ground Control Points (GCPs) ในแปลงตัวอย่าง



ภาพที่ 4 แสดงตำแหน่งการวางจุด GCP ในพื้นที่ศึกษา

การศึกษานี้ได้บินถ่ายภาพพื้นที่ศึกษาด้วยอากาศยานไร้คนขับรุ่น VESPA HEX 650 (HG Robotic company, Thailand) และถ่ายภาพด้วยกล้องมัลติสเปกตรัม (Multispectral imaging camera) ที่มีความยาวหลายช่วงคลื่น โดยประกอบด้วยช่วงคลื่นสำคัญทั้งหมด 5 ช่วงคลื่น (bands) ได้แก่ ช่วงคลื่นสีแดง (Red) สีเขียว (Green) สีน้ำเงิน (Blue) ช่วงคลื่นอินฟราเรดใกล้ (NIR) และช่วงคลื่นขอบแดง (Red Edge) กำหนดพื้นที่บินและวางแผนการบินแบบอัตโนมัติผ่านแอปพลิเคชัน HGMC (HG Robotics HiveGround Mission Control) โดยกำหนดรูปแบบเส้นทางการบิน กำหนดความสูงบิน 44 เมตร ที่ให้ค่าความละเอียดภาพถ่าย (Ground Sampling Distance: GSD) เท่ากับ 3 เซนติเมตร/จุดภาพ กำหนดความเร็วการบิน กำหนดการซ้อนทับด้านหน้า (Front Overlap) เท่ากับ 80% และการซ้อนทับด้านข้าง (Side Overlap) เท่ากับ 60% จากนั้นข้อมูลภาพถ่ายทางอากาศจะถูกนำไปประมวลผลด้วยโปรแกรม Pix4Dmapper เพื่อใช้ในการรวมภาพถ่ายออร์โธ (Orthophoto) และวิเคราะห์ภาพถ่ายเบื้องต้นด้วยโปรแกรม Qgis

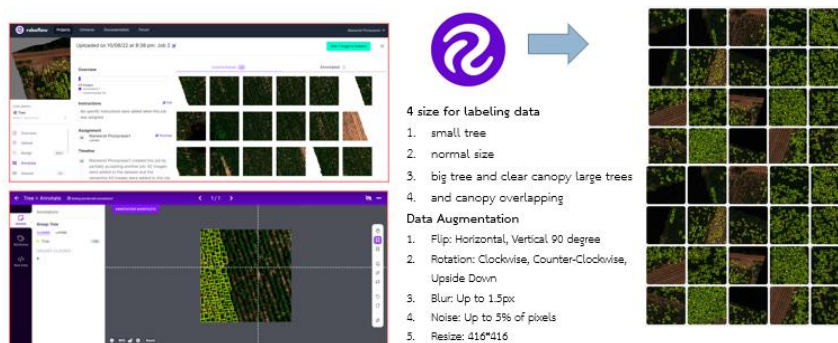


ภาพที่ 5 การสำรวจเพื่อเก็บบันทึกข้อมูลทางกายภาพในส่วนขนาดของต้นมันสำปะหลัง




### 3.2 การเตรียมชุดข้อมูลสำหรับพัฒนาฝึกฝนโมเดล

สำหรับการเตรียมข้อมูลฝึกฝนโมเดลจะนำภาพต้นฉบับของแปลงมันสำปะหลังมาทำการตัดแบ่งเป็นขนาดเล็ก จากนั้นจะนำมาเข้าซอฟต์แวร์ “Roboflow” ซึ่งเป็นเครื่องมือทาง computer vision developer framework เพื่อทำการกำหนดป้ายชื่อ (Labeling) ให้กับต้นมันสำปะหลัง โดยมีการกำหนดลักษณะของภาพต้นมันสำปะหลังที่จะทำการ labeling อยู่ด้วยกัน 4 ลักษณะ ได้แก่ ภาพต้นมันที่มีลักษณะลำต้นขนาดเล็ก ภาพต้นมันที่มีลักษณะลำต้นขนาดกลาง ภาพต้นมันที่มีลักษณะลำต้นขนาดใหญ่ และมีทรงพุ่มชัดเจน และภาพต้นมันที่มีลักษณะลำต้นขนาดใหญ่และมีทรงพุ่มติดกันหนาแน่น แต่ชุดข้อมูลภาพมีจำนวนน้อยเกินไป สำหรับการฝึกฝน จึงต้องมีการเพิ่มปริมาณของภาพที่ใช้ในการฝึกฝนด้วยเทคนิค Data Augmentation โดยใช้รูปแบบการกลับด้าน (Flip: Horizontal, Vertical, 90 องศา) รูปแบบการหมุนภาพ (Rotation: Clockwise, Counter-Clockwise, Upside Down) รูปแบบการเบลอภาพ (Blur: Up to 1.5px) รูปแบบการเพิ่มสัญญาณรบกวนภาพ (Noise: Up to 5% of pixels) และการลดขนาดภาพ (Resize: 416\*416) เพื่อให้ภาพมีขนาดที่เหมาะสมกับโมเดลของอัลกอริทึม YoloV3 ดังแสดงในภาพที่ 6 และภาพที่ 7 จากนั้นจึงทำการแบ่งชุดข้อมูลออกเป็น 3 ส่วน ได้แก่ Train set = 80%, Test set = 10%, Validation = 10% ดังแสดงในภาพที่ 8



ภาพที่ 6 แสดงตัวอย่างภาพข้อมูลการทำ Data Labeling ที่ใช้ในการฝึกฝนโมเดลตรวจจับต้นมันสำปะหลัง




ภาพที่ 7 แสดงตัวอย่างภาพที่ผ่านการทำ Data Labeling

Labeling	Amount
Cassava (y)	251

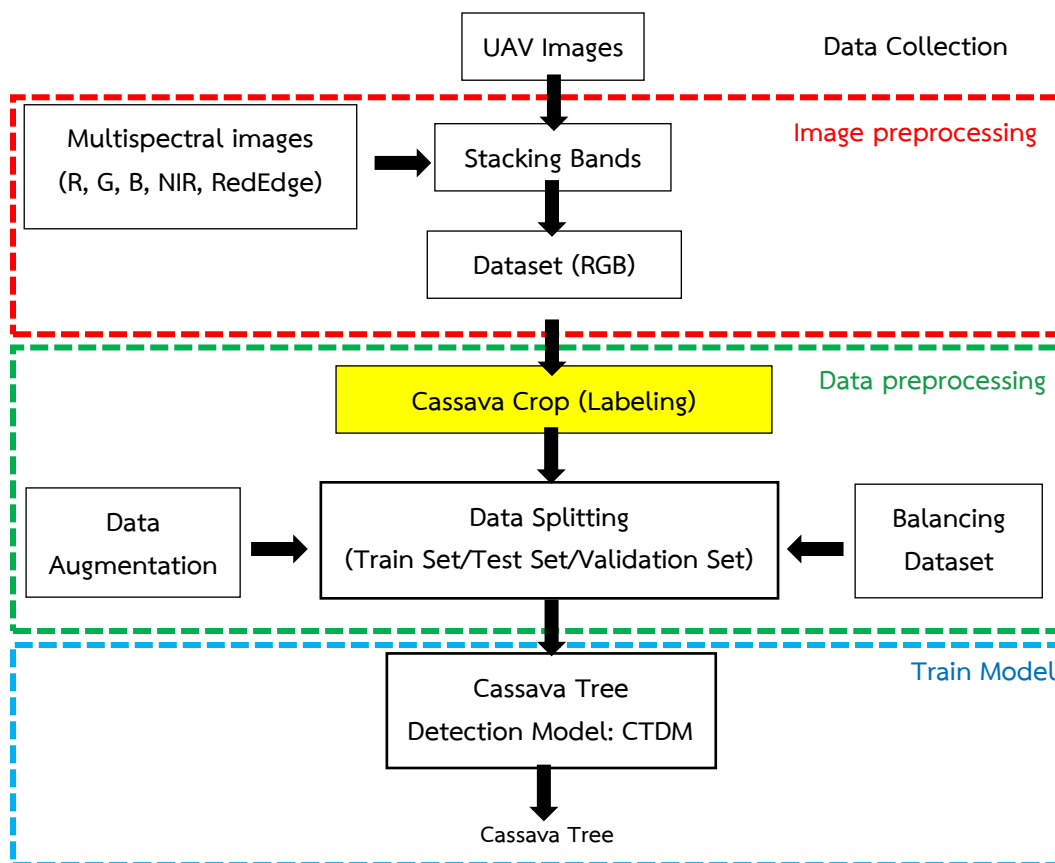
Non-Data augmentation

K-fold cross validation , K=5



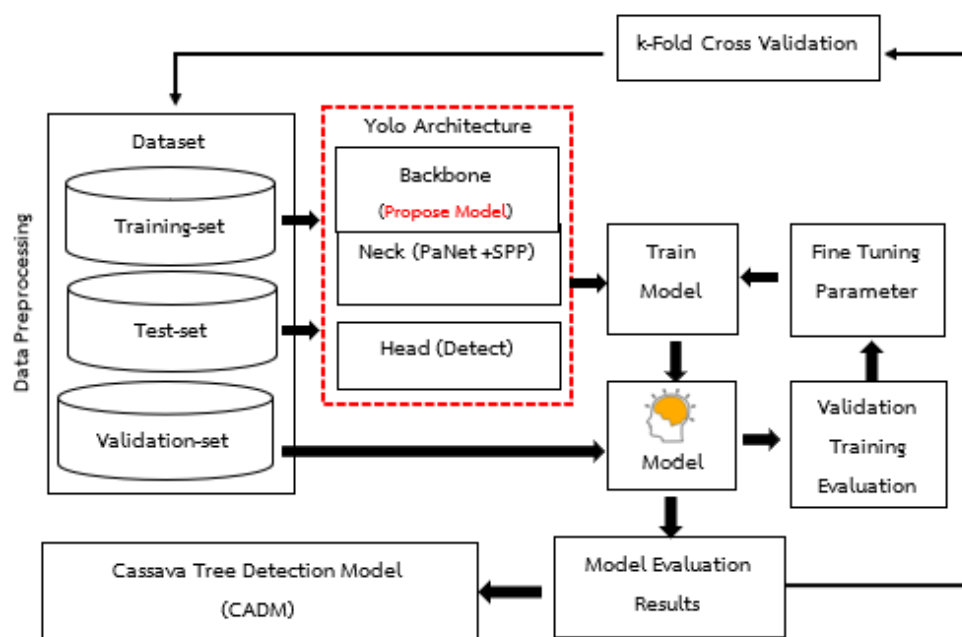
ภาพที่ 8 แสดงตัวอย่างข้อมูลที่ใช้ในการฝึกฝนโมเดลตรวจจับต้นมันสำปะหลัง

#### 4. แผนภาพการวิจัย



ภาพที่ 9 ภาพรวมกระบวนการวางแผนการวิจัย (Research Plan)

#### 5. ขั้นตอนการพัฒนาและการประเมินผลโมเดลตรวจจับต้นมันสำปะหลัง (Cassava Tree Detection Model: CTDM)




ภาพที่ 10 แผนภาพขั้นตอนการพัฒนาโมเดลตรวจจับต้นมันสำปะหลัง

## 6. การวิเคราะห์ข้อมูล

สำหรับการวิเคราะห์ข้อมูลในการออกแบบการทดลองของโมเดลตรวจจับต้นมันสำปะหลัง (CTDM) จะใช้อัลกอริทึม YOLO v3 โดยยังไม่มีมีการปรับแต่งค่า Parameter สำหรับการตรวจจับ จะทำการแบ่งชุดข้อมูลออกเป็น Train 80% และ Test 20% ซึ่งในชุดข้อมูล Train จะแบ่งออกเป็นชุดข้อมูล Validation 10% มีการกำหนดรอบการทำงานที่ Epoch = 100, Batch size = 32, LR = 0.0001, Optimizer = adam ได้ค่า Precision = 76.2%, Recall = 72.7% และ F1-Score = 80.3%

## ผลการวิจัย

จากการวิเคราะห์ข้อมูลภาพจากอากาศยานไร้คนขับด้วยโมเดล YOLO v3 โดยที่ยังไม่มีมีการปรับแต่งค่า parameter สำหรับการตรวจจับต้นมันสำปะหลัง พบว่า แบบจำลองโมเดล YOLO v3 สามารถนำมาใช้ตรวจจับต้นมันสำปะหลังจากได้ โดยได้ค่า ค่า mAP เท่ากับ 80.3% ค่า precision เท่ากับ 76.2% และค่า recall เท่ากับ 72.7% ซึ่งชุดข้อมูล train loss และ validation loss ให้ผลที่ใกล้เคียงกัน



ภาพที่ 11 ผลการทดลองพัฒนาโมเดลตรวจจับต้นมันสำปะหลังโดยใช้อัลกอริทึม YOLO v3

## อภิปรายผล

จากผลการวิจัยแสดงให้เห็นว่า การบินถ่ายภาพเก็บข้อมูลด้วยกล้องที่ติดบนอากาศยานไร้คนขับ เพื่อตรวจจับต้นมันสำปะหลัง ที่ความสูงบิน 44 เมตร ที่ความละเอียดจุดภาพ (GSD) 3 ซม. โดยทำการประเมินประสิทธิภาพของโมเดลตรวจจับต้นมันสำปะหลัง โดยรวมด้วยอัลกอริทึม YOLO v3 ที่ค่า mAP เท่ากับ 80.3% โดยสอดคล้องกับงานวิจัยของ M. Kerkech, A. Hafiane and R. Canals. (2020) โดยใช้ภาพสะท้อนช่วงคลื่น RGB เพียงอย่างเดียวเหมือนกัน อีกทั้งโมเดลในงานวิจัยนี้ยังไม่มีมีการปรับค่า parameter ของโมเดลแต่อย่างใด ซึ่งงานวิจัยนี้มุ่งเน้นใช้ค่าสะท้อนแสงช่วงคลื่นให้สามารถทดสอบตรวจจับต้นมันสำปะหลังได้ ซึ่งอาจทำให้ผลการวิเคราะห์ข้อมูลมีความแปรผันมาก เนื่องจากการวิจัยครั้งนี้เป็นการทดลองกับตัวอย่างที่เป็นแปลงปลูกมันสำปะหลังเพียง 1 แปลงรวมถึงภาพที่ได้จากอากาศยานไร้คนขับอาจมีความคลาดเคลื่อนในส่วนของมุมกล้อง การรับแสง และความเอียงเนื่องจากแรงลมในขณะทำการบิน อีกทั้งความละเอียดจุดภาพอาจจะยังไม่ละเอียดพอ หากต้องการตรวจจับต้นมันสำปะหลังให้มีความแม่นยำสูงอาจจะต้องใช้การวิเคราะห์ผลค่าดัชนีพืชพรรณร่วมด้วย

## สรุปผลการวิจัย

จากการศึกษาวิจัยในครั้งนี้แสดงให้เห็นว่าค่าการสะท้อนแสงจากข้อมูลภาพ RGB จากอากาศยานไร้คนขับ สามารถนำมาใช้เป็นข้อมูลนำเข้าในแบบจำลอง YOLO v3 เพื่อใช้ตรวจจับต้นมันสำปะหลังได้ดีในระดับเบื้องต้นเท่านั้น หากมีการเพิ่มความสามารถในการปรับค่า Hyperparameter ของโมเดล และมีการปรับแต่งโครงสร้างของ Backbone ในส่วนของการกำหนดโครงสร้างชั้นสกัดคุณลักษณะ รวมถึงการทดลองจับคู่ Hyperparameter ของโมเดลด้วยจะช่วยให้ผลการตรวจจับได้ดียิ่งขึ้น

## ข้อเสนอแนะ

ข้อเสนอแนะในการนำผลการวิจัยไปใช้

1. ควรนำไปใช้กับมันสำปะหลังที่มีอายุตั้งแต่ 3 เดือน เพราะยังสามารถเห็นภาพทรงพุ่มของต้นมันสำปะหลังได้ชัดเจน
2. ควรนำไปใช้กับมันสำปะหลังพันธุ์เกษตรศาสตร์ 50 เพื่อความแม่นยำในการตรวจจับ

ข้อเสนอแนะสำหรับการวิจัยครั้งต่อไป

1. ควรมีการใช้โมเดลด้านงาน Detection อื่นๆ เพิ่มเติม ซึ่งจะช่วยให้ได้โมเดลที่มีประสิทธิภาพมากที่สุด
2. ควรมีการเปรียบเทียบกับ YOLO เวอร์ชันอื่นๆ ด้วย

## เอกสารอ้างอิง

- ชัตติยานี ศรีแฉล้ม และ คณะ (2561). การศึกษาค่าสะท้อนพลังงานของมันสำปะหลังจากข้อมูลดาวเทียมในเขตอำเภอโชคชัย จังหวัดนครราชสีมา. *วารสารวิจัยและพัฒนา วไลยอลงกรณ์ในพระบรมราชูปถัมภ์ สาขาวิทยาศาสตร์และเทคโนโลยี*, 13(3), 12-22.
- สำนักงานเศรษฐกิจการเกษตร. (2563). สถานการณ์การผลิตมันสำปะหลังโรงงานย้อนหลัง 5 ปีล่าสุด. สำนักงานเศรษฐกิจการเกษตร. <<http://mis-app.oae.go.th/product/มันสำปะหลัง โรงงาน>> (สืบค้นเมื่อ 20 เดือนตุลาคม 2564).
- สำนักวิจัยพัฒนาการอารักขาพืช กรมวิชาการเกษตร. (2561). คู่มือการสำรวจและเฝ้าระวัง โรคใบด่างของมันสำปะหลังเบื้องต้น. กรุงเทพฯ: กรมวิชาการเกษตร.
- Abdullakasm, W., Powbunthorn, K., Unartngam, J., and Takigama, T. (2011). An images analysis technique for recognition of brown leaf spot disease in cassava. *Tarım. Makinaları. Bilimi. Dergisi*, 7, 165–169.
- Aduwo, J. R., Mwebaze, E., and Quinn, J. A. (2010). **Automated vision-based diagnosis of Cassava Mosaic Disease**, in *Industrial Conference on Data Mining-Workshops* (New York, NY), 114–122.
- Dubey, S. R., and Jalal, A. S. (2014). **Adapted approach for fruit disease identification using images**. arXiv preprint arXiv: 1405.4930.
- Durmu,s, H., Güne,s, E. O., and Kirci, M. (2017). Disease detection on the leaves of the tomato plants by using deep learning, in **2017 6th International Conference on Agro-Geoinformatics** (Fairfax, VA: IEEE), 1–5. doi: 10.1109/Agro-Geoinformatics.2017.8047016.
- Fuentes, A., Yoon, S., Kim, S. C., and Park, D. S. (2017). **A robust deep-learning based detector for real-time tomato plant diseases and pests recognition**. *Sensors* 17: 2022. doi: 10.3390/s17092022.
- Gibson, D., Burghardt, T., Campbell, N., and Canagarajah, N. (2015). Towards automating visual in-field monitoring of crop health, in **IEEE International Conference on Image Processing (ICIP)**, 2015 (Quebec City, QC: IEEE), 3906–3910.
- Kumar, M., Gupta, P., and Madhav, P. (2020). Disease detection in coffee plants using convolutional neural network, in **2020 5th International Conference on Communication and Electronics Systems (ICCES)** (Coimbatore: IEEE), 755–760. doi: 10.1109/ICCES48766.2020.9138000.
- Liu, B., Ding, Z., Tian, L., He, D., Li, S., and Wang, H. (2020). **Grape leaf disease identification using improved deep convolutional neural networks**. *Front. Plant Sci.* 11:1082. doi: 10.3389/fpls.2020.01082.
- Liu, B., Zhang, Y., He, D., and Li, Y. (2017). **Identification of apple leaf diseases based on deep convolutional neural networks**. *Symmetry* 10:11. doi:10.3390/sym10010011.
- M Dian Bah., Adel Hafiane., and Raphael Canals. (2018). Deep Learning with Unsupervised Data Labeling for Weed Detection in Line Crops in UAV Images., *Remote Sens*, 10, 1690; doi:10.3390/rs10111690.
- M. Kerkech, A. Hafiane and R. Canals. (2020). Vine disease detection in UAV multispectral images using optimized image registration and deep learning segmentation approach. *Computers and Electronics in Agriculture*, 174 (2020). <<http://doi.org/10.1016/j.compag.2020.105446>>
- M. Kerkech, A. Hafiane. (2018). Deep learning approach with colorimetric spaces and vegetation indices for vine diseases detection in UAV images. *Computers and Electronics in Agriculture*, 155(2018), 237-243. <<http://doi.org/10.1016/j.compag.2018.10.006>>
- Metlek S., (2021). “Disease Detection From Cassava Leaf Images With Deep Learning Methods In Web Environment” *Int. J. of 3D printing Tech. Dig. Ind.*, 5(3), 625-644, (2021).
- Mwebaze, E., and Owomugisha, G. (2016). Machine learning for plant disease incidence and severity measurements from leaf images, in **Machine Learning and Applications (ICMLA)**, 2016 15th IEEE International Conference on (IEEE) (Anaheim, CA).
- Puig, E., Gonzalez, F., Hamilton, G., and Grundy, P. (2015). Assessment of crop insect damage using unmanned aerial systems: a machine learning approach, in **21st International Congress on Modelling and Simulation (MODSIM2015)**, (Gold Coast, QLD). Available online at: <https://eprints.qut.edu.au/95241/>.